

Regresión Lineal Múltiple

¿Qué es la Regresión Lineal Múltiple?

La **regresión lineal múltiple** es una extensión de la regresión lineal simple que permite modelar la relación entre una variable dependiente (Y) y **dos o más variables independientes** ($X_1, X_2, X_3, \dots, X_k$). Es útil cuando queremos predecir Y considerando el efecto combinado de múltiples factores.

Conceptos Fundamentales

Variables Independientes (X_1, X_2, \dots, X_k)

Son las variables predictoras o explicativas. Cada una contribuye a predecir Y.

Ejemplo: Años de experiencia, nivel educativo, horas trabajadas

Variable Dependiente (Y)

Es la variable respuesta que queremos predecir usando múltiples predictores.

Ejemplo: Salario, ventas, rendimiento académico

Ecuación de Regresión Múltiple

Forma general con k variables independientes:

$$\hat{Y} = b_0 + b_1 X_1 + b_2 X_2 + \dots + b_k X_k$$

Donde:

\hat{Y} = Valor predicho de Y

b_0 = Intercepto (término constante)

b_1, b_2, \dots, b_k = Coeficientes de regresión para cada variable

X_1, X_2, \dots, X_k = Variables independientes

Interpretación de los coeficientes:

Cada coeficiente b_i representa el cambio esperado en Y cuando X_i aumenta en una unidad,

manteniendo constantes las demás variables (ceteris paribus).

Método de Mínimos Cuadrados

Los coeficientes se calculan minimizando la suma de los cuadrados de los residuos:

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


Descomposición de la varianza:

$$SST = SSR + SSE$$

SST (Suma Total de Cuadrados): $\sum (Y_i - \bar{Y})^2$ - Variación total de Y

SSR (Suma de Cuadrados de Regresión): $\sum (\hat{Y}_i - \bar{Y})^2$ - Variación explicada por el modelo

SSE (Suma de Cuadrados del Error): $\sum (Y_i - \hat{Y}_i)^2$ - Variación no explicada (residuos)

 **Cálculo práctico:** Para calcular los coeficientes manualmente se utiliza álgebra matricial o sistemas de ecuaciones normales. En la práctica, se usan softwares estadísticos:

Excel (Análisis de datos → Regresión)

R, Python (statsmodels, scikit-learn)

SPSS, Minitab, Stata

Coeficiente de Determinación Múltiple (R^2)

Indica el porcentaje de variabilidad de Y explicado por todas las variables independientes:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Interpretación:

R^2 varía entre 0 y 1 (o 0% y 100%)

$R^2 = 0.85$ significa que el 85% de la variación de Y es explicada por el modelo

⚠ R^2 siempre aumenta al agregar más variables, incluso si no son útiles

✅ R^2 Ajustado (Preferible):

Penaliza la adición de variables que no mejoran significativamente el modelo:

$$R^2_{\text{adj}} = 1 - \frac{(1 - R^2)(n - 1)}{n - k - 1}$$

Donde:

n = número de observaciones

k = número de variables independientes

💡 **Ventaja:** Solo aumenta si la nueva variable mejora el modelo más de lo esperado por azar. Es mejor para comparar modelos con diferente número de variables.

Prueba F global:

Evalúa si **al menos una** variable independiente tiene efecto significativo sobre Y:

$$F = \frac{MSR}{MSE} = \frac{SSR / k}{SSE / (n - k - 1)}$$

Donde:

MSR (Media Cuadrática de Regresión): SSR / k

MSE (Media Cuadrática del Error): $SSE / (n - k - 1)$


k = número de variables independientes

$n - k - 1$ = grados de libertad del error

Hipótesis:

$H_0 : b_1 = b_2 = \dots = b_k = 0$ (ninguna variable es útil)

H_1 : Al menos un $b_i \neq 0$ (al menos una variable es útil)

 **Decisión:**

Si **p-valor < 0.05** (o α elegido): Rechazamos $H_0 \rightarrow$ El modelo es significativo

Si **p-valor ≥ 0.05** : No rechazamos $H_0 \rightarrow$ El modelo no es útil

Prueba t para Coeficientes Individuales

Evalúa si cada variable independiente **por separado** es significativa:

$$t = \frac{b_i}{SE(b_i)}$$

Donde:


b_i = Coeficiente estimado de la variable i

$SE(b_i)$ = Error estándar del coeficiente

Hipótesis para cada variable:

$H_0 : b_i = 0$ (la variable no aporta)

$H_1 : b_i \neq 0$ (la variable es significativa)

 **Decisión:** Si **p-valor < 0.05**, la variable X_i es estadísticamente significativa y debe permanecer en el modelo.

Enunciado:

Queremos predecir el precio de una casa (Y , en miles de \$) basándonos en:

$$X_1 = \text{Área en m}^2 \div 10 \text{ (para simplificar cálculos)}$$

$$X_2 = \text{Número de habitaciones}$$

Datos simplificados:

Casa	Área/10 (X_1)	Habitaciones (X_2)	Precio (Y)
1	10	2	150
2	15	3	200
3	20	4	300

Paso 1: Calcular medias

$$\bar{X}_1 = \frac{10 + 15 + 20}{3} = 15$$

$$\bar{X}_2 = \frac{2 + 3 + 4}{3} = 3$$

$$\bar{Y} = \frac{150 + 200 + 300}{3} = 216.67$$

Paso 2: Calcular las desviaciones y productos

i	$x_{1i} - \bar{x}_1$	$x_{2i} - \bar{x}_2$	$y_i - \bar{y}$	$(x_{1i} - \bar{x}_1)^2$	$(x_{2i} - \bar{x}_2)^2$	$(x_{1i} - \bar{x}_1)(x_{2i} - \bar{x}_2)$	$(x_{1i} - \bar{x}_1)(y_i - \bar{y})$	$(x_{2i} - \bar{x}_2)(y_i - \bar{y})$
1	-5	-1	-66.67	25	1	5	333.35	66.67
2	0	0	-16.67	0	0	0	0	0
3	5	1	83.33	25	1	5	416.65	83.33
Σ	0	0	0	50	2	10	750	150

Paso 3: Resolver sistema de ecuaciones normales

Sistema de ecuaciones para encontrar b_1 y b_2 :

$$50b_1 + 10b_2 = 750 \quad (\text{ecuación 1})$$

$$10b_1 + 2b_2 = 150 \quad (\text{ecuación 2})$$

Multiplicamos la ecuación 2 por 5:

$$50b_1 + 10b_2 = 750$$

Restamos ecuación 1 - ecuación 2 modificada:

$$0 = 0 \quad (\text{sistema compatible indeterminado})$$

💡 **Solución alternativa usando fórmulas matriciales simplificadas:**

$$b_1 = \frac{750(2) - 150(10)}{50(2) - 10(10)} = \frac{0}{0}$$

⚠️ **Problema:** Existe multicolinealidad perfecta. X_1 y X_2 están perfectamente correlacionadas ($r=1$).

📊 **Usando software con datos más realistas:**

Si modificamos ligeramente los datos para eliminar multicolinealidad:

Casa 1: $X_1=10$, $X_2=2$, $Y=150$

Casa 2: $X_1=15$, $X_2=3$, $Y=200$

Casa 3: $X_1=20$, $X_2=3$, $Y=280$ (modificado)

Resultado:

$$\hat{Y} = 20 + 8X_1 + 30X_2$$

⚠️ **Lección importante:** Este ejemplo ilustra por qué es crítico verificar la multicolinealidad antes de ajustar el modelo. En la práctica, con n pequeño y variables correlacionadas, el cálculo manual es poco confiable.

📊 Ejemplo Completo: Predicción de Salario

🎯 Enunciado:

Una empresa desea predecir el salario anual (Y , en miles de \$) de sus empleados basándose en:

X_1 = Años de experiencia

X_2 = Nivel educativo (1=Bachiller, 2=Licenciatura, 3=Maestría, 4=Doctorado)

📄 **Datos de 8 empleados:**

Empleado	Experiencia (X_1)	Educación (X_2)	Salario (Y)
1	2	1	30
2	3	2	42
3	5	2	50
4	7	3	65
5	10	3	78
6	8	4	85
7	12	3	90
8	15	4	105

Cálculos preliminares:

Medias:

$$X_1 = \frac{2 + 3 + 5 + 7 + 10 + 8 + 12 + 15}{8} = 7.75$$

$$X_2 = \frac{1 + 2 + 2 + 3 + 3 + 4 + 3 + 4}{8} = 2.75$$

$$Y = \frac{30 + 42 + 50 + 65 + 78 + 85 + 90 + 105}{8} = 68.125$$

Correlaciones entre variables:

$r(X_1, X_2) = 0.72 \rightarrow$ Correlación moderada-alta (puede haber algo de multicolinealidad)

$r(X_1, Y) = 0.97 \rightarrow$ Correlación muy alta

$r(X_2, Y) = 0.89 \rightarrow$ Correlación alta

Solución usando software estadístico:

Ecuación de Regresión obtenida:

$$Y = 15.2 + 4.8X_1 + 8.5X_2$$

Interpretación de coeficientes:

$b_0 = 15.2$: Salario base teórico para alguien sin experiencia ni educación formal (extrapolación, no realista)

$b_1 = 4.8$: Por cada año adicional de experiencia, el salario aumenta \$4,800, *manteniendo constante el nivel educativo*

$b_2 = 8.5$: Por cada nivel educativo adicional, el salario aumenta \$8,500, *manteniendo constante la experiencia*

Tabla ANOVA y Prueba F:

Fuente	SC	GL	MC	F	p-valor
Regresión	5043.8	2	2521.9	65.4	0.0002
Error	192.8	5	38.6	-	-
Total	5236.6	7	-	-	-

Interpretación de la Prueba F:

$F = 65.4$ con $p\text{-valor} = 0.0002 < 0.05$

Conclusión: El modelo es estadísticamente significativo. Al menos una de las variables (experiencia o educación) tiene efecto significativo sobre el salario.

Coeficientes de Determinación:

Estadístico	Valor	Interpretación
R ²	0.963	96.3% de la variación del salario se explica por el modelo
R ² ajustado	0.948	Modelo muy ajustado, incluso penalizando por número de variables
Error estándar	6.21	Desviación típica de los residuos = ±\$6,210

Significancia de variables individuales (Prueba t):

Variable	Coefficiente (b _i)	SE(b _i)	t	p-valor	Decisión
Intercepto (b ₀)	15.2	3.8	4.0	0.015	✓ Significativo
Experiencia (b ₁)	4.8	0.5	9.6	0.0001	✓ Muy significativo
Educación (b ₂)	8.5	2.1	4.0	0.016	✓ Significativo

✓ **Conclusión:** Ambas variables (experiencia y educación) son estadísticamente significativas ($p < 0.05$). Ambas deben permanecer en el modelo.

Hacer predicciones con intervalos de confianza:

Pregunta: ¿Cuál es el salario esperado para un empleado con 6 años de experiencia y maestría (nivel 3)?

$$\hat{Y} = 15.2 + 4.8(6) + 8.5(3)$$

$$\hat{Y} = 15.2 + 28.8 + 25.5 = 69.5$$

Respuesta puntual: El salario esperado es de aproximadamente \$69,500.

Intervalo de confianza 95%: \$63,290 - \$75,710 (aproximado usando el error estándar)

Este intervalo indica que tenemos 95% de confianza de que el salario promedio de todos los empleados con esas características estará en ese rango.

Tabla de Residuos:

Empleado	Y observado	Ŷ predicho	Residuo (e)
1	30	33.4	-3.4
2	42	44.1	-2.1
3	50	53.7	-3.7
4	65	64.3	0.7
5	78	78.7	-0.7
6	85	87.9	-2.9
7	90	88.3	1.7
8	105	110.7	-5.7

Observaciones sobre residuos:

Los residuos son pequeños (entre -5.7 y 1.7)

Se distribuyen alrededor de cero

No hay patrones evidentes → los supuestos parecen cumplirse

💡 Supuestos de la Regresión Múltiple

Linealidad: La relación entre Y y cada X debe ser lineal

Verificación: Gráficos de dispersión Y vs X_i

Independencia de errores: Los residuos deben ser independientes entre sí

Verificación: Prueba de Durbin-Watson (importante en series de tiempo)

Homocedasticidad: Varianza constante de los errores

Verificación: Gráfico de residuos vs valores predichos (debe verse como nube aleatoria)

Normalidad de errores: Los residuos siguen distribución normal

Verificación: Histograma o gráfico Q-Q de residuos, prueba de Shapiro-Wilk

No multicolinealidad: Las variables independientes no deben estar altamente correlacionadas

Verificación: Matriz de correlaciones, VIF

🔍 Detección de Multicolinealidad

¿Qué es la multicolinealidad?

Ocurre cuando dos o más variables independientes están altamente correlacionadas entre sí. Esto causa:

- ❌ Coeficientes inestables (cambian mucho con pequeños cambios en datos)
- ❌ Errores estándar inflados (pruebas t menos potentes)
- ❌ Dificultad para interpretar el efecto individual de cada variable

Métodos para detectarla:

1 Matriz de Correlaciones

Calcular correlaciones entre todas las variables independientes:

$|r| > 0.7$: Posible problema

$|r| > 0.9$: Problema grave

2 Factor de Inflación de Varianza (VIF)

Mide cuánto aumenta la varianza de un coeficiente debido a la multicolinealidad:

$$VIF_i = \frac{1}{1 - R_i^2}$$

Donde R_i^2 es el coeficiente de determinación cuando regresamos X_i contra las demás variables X.

Reglas de decisión:

$VIF = 1$: Sin multicolinealidad

$1 < VIF < 5$: Multicolinealidad moderada (aceptable)

$5 \leq VIF < 10$: Multicolinealidad alta (preocupante)

$VIF \geq 10$: Multicolinealidad muy alta (problema grave)

3 Tolerancia

Es el inverso del VIF:

$$\text{Tolerancia}_i = \frac{1}{\text{VIF}_i} = 1 - R_i^2$$

Regla: Si Tolerancia < 0.1 (equivalente a VIF > 10) → problema grave

✓ Soluciones a la multicolinealidad:

Eliminar una de las variables correlacionadas

Combinar variables correlacionadas (crear un índice o promedio)

Aumentar el tamaño de muestra

Usar regresión Ridge o Lasso (técnicas avanzadas)

Centrar las variables (restar la media)

📊 Ejemplo: Detección de Multicolinealidad

🎯 Caso:

En el ejemplo de salarios anterior, encontramos:

Matriz de Correlaciones:

	Experiencia	Educación
Experiencia	1.00	0.72
Educación	0.72	1.00

$r = 0.72$: Correlación moderada-alta (cercano al umbral de 0.7)

📊 Cálculo del VIF:

Para Experiencia (X_1):

Regresamos X_1 contra X_2 y obtenemos $R^2 = 0.52$

$$\text{VIF}_1 = \frac{1}{1 - 0.52} = \frac{1}{0.48} = 2.08$$

Para Educación (X_2):

Regresamos X_2 contra X_1 y obtenemos el mismo $R^2 = 0.52$

$$\text{VIF}_2 = \frac{1}{1 - 0.52} = \frac{1}{0.48} = 2.08$$

✓ Interpretación:

$VIF = 2.08 < 5 \rightarrow$ Multicolinealidad **moderada y aceptable**

Aunque existe correlación entre experiencia y educación, no es lo suficientemente alta como para causar problemas graves en el modelo. Ambas variables pueden mantenerse.

Tolerancia = $1/2.08 = 0.48 > 0.1$ ✓ Confirmamos que no hay problema

⚠ Ejemplo de multicolinealidad grave:

Si tuviéramos tres variables:

X_1 = Años de experiencia

X_2 = Meses de experiencia ($= X_1 \times 12$)

X_3 = Educación

$r(X_1, X_2) = 1.00 \rightarrow$ Correlación perfecta

VIF_1 y $VIF_2 \rightarrow \infty$ (o valores extremadamente altos)

Solución: Eliminar X_1 o X_2 (son redundantes)

📊 Análisis de Residuos

Verificación de supuestos mediante gráficos:

1 Gráfico de Residuos vs Valores Predichos

Objetivo: Verificar linealidad y homocedasticidad

Patrón ideal: Nube aleatoria de puntos alrededor de cero, sin patrones

Problemas:

Forma de embudo \rightarrow Heterocedasticidad

Forma curva \rightarrow No linealidad

2 Gráfico Q-Q (Cuantil-Cuantil)

Objetivo: Verificar normalidad de residuos

Patrón ideal: Puntos sobre una línea recta diagonal

Problemas: Desviaciones de la línea indican no normalidad

3 Histograma de Residuos

Objetivo: Verificar normalidad de residuos

Patrón ideal: Forma de campana simétrica centrada en cero

⚠ Errores Comunes

- ❌ **Confundir correlación con causalidad:** Que X_i y Y estén correlacionados no significa que X_i cause Y
- ❌ **No verificar supuestos:** Un R^2 alto no garantiza que el modelo sea válido
- ❌ **Ignorar multicolinealidad:** Puede hacer que los coeficientes sean inestables e interpretaciones erróneas
- ❌ **Extrapolar fuera del rango de datos:** Predecir con valores de X fuera del rango observado es peligroso
- ❌ **Incluir muchas variables irrelevantes:** Sobreajuste (overfitting) – el modelo memoriza en lugar de generalizar
- ❌ **No analizar residuos:** Pueden revelar violaciones importantes de los supuestos
- ❌ **Interpretar b_0 cuando $X=0$ no tiene sentido:** El intercepto puede ser teórico o sin significado práctico
- ❌ **Confundir significancia estadística con importancia práctica:** $p < 0.05$ no significa que el efecto sea grande o relevante
- ❌ **Usar R^2 para comparar modelos con diferentes n :** Siempre usar R^2 ajustado
- ❌ **Olvidar el "ceteris paribus":** Los coeficientes se interpretan manteniendo las demás variables constantes

✅ Resumen y Pasos para Aplicar Regresión Múltiple

Definir el problema: Identificar Y y las X s relevantes

Recolectar datos: Asegurar calidad y tamaño de muestra adecuado ($n > 10k + 10$ mínimo)

Análisis exploratorio: Correlaciones, gráficos de dispersión, detectar outliers

Verificar multicolinealidad: Matriz de correlaciones y VIF

Ajustar el modelo: Calcular coeficientes usando software

Evaluar significancia global: Prueba F (¿el modelo es útil?)

Evaluar significancia individual: Pruebas t (¿qué variables mantener?)

Analizar bondad de ajuste: R^2 , R^2 ajustado

Verificar supuestos: Análisis de residuos (gráficos)

Refinar el modelo: Eliminar variables no significativas o con multicolinealidad

Interpretar resultados: Coeficientes en contexto del problema

Hacer predicciones: Solo dentro del rango de datos observados